

Análisis de Datos para la Gestión de la Seguridad

Especialización en Gerencia en Seguridad de las Organizaciones

Docente

Sergio Andrés Fuentes Gómez

Institución

Escuela de Posgrados de Policía – ESPOL

Tema

Ecosistema de datos

Datos Estructurados: Orden y Rigidez Tabular

Definición esencial

Tipo de dato tradicional con el **nivel más alto de organización** disponible en el ecosistema de datos. Su característica central es la predictibilidad total de su forma.

Características fundamentales

- Residen en un **formato fijo y predefinido**; encajan de manera natural en tablas con filas y columnas.
- Cada columna tiene un **nombre y un tipo de dato explícito** (texto, número, fecha).
- Cada fila constituye un **registro único** e identificable dentro del conjunto.

📌 El dato estructurado es el punto de partida histórico del Business Intelligence: toda la arquitectura relacional clásica se construye sobre este paradigma.

Atributos Clave de los Datos Estructurados

Formato Fijo y Predeterminado

Siguen un esquema rígido que define la estructura **antes** de que los datos ingresen. El diseño del modelo precede siempre a la carga de información.

Fácilmente Consultables

Se manipulan y ordenan con gran eficiencia mediante lenguajes estándar como **SQL**. La estandarización del lenguaje reduce la curva de aprendizaje y acelera el análisis.

Almacenamiento

Operan en motores relacionales tradicionales: **MySQL, PostgreSQL, Oracle, SQL Server**. Tecnologías maduras con décadas de optimización y soporte empresarial.

Optimización Analítica

Ideales para **operaciones numéricas, agregaciones y modelos estadísticos** directos. La regularidad del esquema habilita índices y planes de ejecución altamente eficientes.

Menor Complejidad de ETL

Estructura uniforme que **facilita las tareas de extracción, transformación y carga**. Los pipelines son más predecibles y menos propensos a errores de integración.

Casos de Aplicación en la Operación Empresarial

Bases de datos de clientes

Nombres, direcciones, teléfonos, correos electrónicos. El registro maestro de clientes es el activo estructurado más crítico de cualquier organización comercial.

Registros de transacciones financieras

Fechas, montos, IDs de transacción, ítems comprados. Cada operación queda capturada en campos discretos que permiten auditoría y conciliación automática.

Sistemas de inventario

Códigos SKU, cantidades en existencia, costos unitarios, precios de venta. La trazabilidad de stock depende de la integridad del esquema tabular.

Datos de recursos humanos

Nóminas, salarios, fechas de contratación, cargos y departamentos. La gestión del talento y la planificación de fuerza laboral se apoyan en estos registros estructurados.

Datos Estructurados: El Núcleo Tradicional del BI

Rol central en la arquitectura de BI

Los datos estructurados son la **columna vertebral de los almacenes de datos (Data Warehouses) corporativos**. Toda la cadena de valor analítica clásica —desde la ingesta hasta el reporte— fue diseñada en torno a este paradigma.

Facilitan la **generación automatizada de reportes financieros** y tableros operativos de control, permitiendo ciclos de reporting periódicos con alta confiabilidad y reproducibilidad.


Ventaja

Alta consistencia y velocidad de consulta. Los esquemas predefinidos permiten optimizaciones de motor que reducen los tiempos de respuesta a milisegundos incluso sobre millones de registros.

Limitación

Dificultad y costo elevado para cambiar de esquema si el modelo de negocio evoluciona rápidamente. Las migraciones de esquema en producción son operaciones de alto riesgo y larga planificación.

Datos Semiestructurados: El Híbrido Flexible



Posición en el espectro

Puente intermedio entre el **orden tabular rígido** y el desorden absoluto. No son ni completamente predecibles ni completamente caóticos: tienen estructura, pero no la imponen de forma rígida.

Mecanismo de organización

Poseen una estructura interna, pero **no siguen un esquema fijo de filas y columnas**. Utilizan etiquetas, marcadores o parejas atributo-valor para jerarquizar y separar los elementos de información.

Atributos Clave de los Datos Semiestructurados

Estructura Flexible

No requieren un esquema rígido previo a su almacenamiento; los **campos pueden variar entre registros** sin invalidar el conjunto de datos.

Etiquetas y Marcadores

Uso de **delimitadores explícitos** para organizar y dar sentido a cada elemento. La semántica está embebida en el propio dato.

Jerarquías Complejas

Organización típica en **árboles o grafos con anidamiento de datos**. Un registro puede contener sub-registros de profundidad variable.

Lectura Mixta

Diseñados para ser interpretados **tanto por humanos como por sistemas informáticos**. Esta dualidad los hace ideales para intercambio de información entre sistemas heterogéneos.

Almacenamiento NoSQL

Reposan en **bases de datos documentales (MongoDB, Cassandra)** o repositorios distribuidos. Arquitecturas diseñadas para escalar horizontalmente con datos de forma variable.

Formatos y Fuentes Habituales en la Organización



JSON (JavaScript Object Notation)

Estándar ligero basado en **pares atributo-valor**, vital en APIs e integraciones web. Es el formato dominante en la comunicación entre microservicios y aplicaciones modernas.



XML (eXtensible Markup Language)

Formato anidado con etiquetas, ampliamente usado en **facturación electrónica y convenios interempresariales**. Estándar de facto en integraciones B2B y sistemas legados.



Archivos de Registro (Logs) de servidores

Marcas de tiempo e IPs con estructura fija, combinadas con **mensajes y rutas de longitud variable**. Fuente crítica para auditoría de seguridad y análisis de comportamiento de sistemas.



Cabeceras de Email y CSVs irregulares

Metadatos claros (remitente, asunto, fecha) con **esquemas no siempre tabulares**. La irregularidad de los CSVs con columnas opcionales los acerca al territorio semiestructurado.

Matriz Comparativa de Enfoques

Comparación directa entre los dos paradigmas de datos abordados en el bloque, evaluados en las dimensiones más relevantes para la práctica de BI.

Criterio	Datos Estructurados	Datos Semiestructurados
Esquema	Rígido y predefinido (Schema-on-Write)	Dinámico y flexible (Schema-on-Read)
Organización	Tablas relacionales (filas y columnas)	Árboles, grafos o pares atributo-valor
Lenguaje / Gestor	SQL / Bases de datos relacionales (RDBMS)	NoSQL / Documentales (JSON, XML, MongoDB)
Facilidad de consulta	Inmediata y altamente estandarizada	Requiere desempaquetar etiquetas y jerarquías
Adaptabilidad al cambio	Baja (modificar tablas cuesta tiempo y dinero)	Alta (soporta nuevos campos sin alterar registros previos)

Datos No Estructurados: Volumen, Riqueza y Complejidad

Dato clave

80%

del volumen corporativo digital corresponde a datos no estructurados — la categoría más grande y de más rápido crecimiento en el ecosistema digital.

Características definitorias

Sin esquema predefinido

Carecen por completo de una estructura organizacional fija o esquema predefinido.

Forma nativa y sin procesar

Se presentan en su estado original; no encajan en bases de datos relacionales tradicionales.

Multiplicidad de medios y analítica avanzada

Alto volumen y velocidad. Requieren PLN y visión computacional para su aprovechamiento.

Fuentes No Estructuradas en la Empresa



Documentos de texto

Correos (cuerpo del mensaje), archivos PDF, contratos legales, informes en Word.



Archivos multimedia

Grabaciones de llamadas de atención al cliente, audios, imágenes y videos corporativos.



Canales digitales

Publicaciones, reseñas de clientes, interacciones en redes sociales.



Flujos brutos de sensores (IoT)

Señales continuas de maquinaria, temperatura o rastreo operativo.



Contenido web y HTML

Texto libre, artículos y páginas web del sector.

Los 5 Retos del Ecosistema de Datos

1 Integración

Combinar fuentes heterogéneas mediante arquitecturas robustas de ETL/ELT.

2 Almacenamiento

Despliegue de repositorios escalables y elásticos como Data Lakes.

3 Procesamiento y Análisis

Uso de algoritmos de Machine Learning y PLN para extraer patrones en texto o audio.

4 Calidad de Datos

Asegurar consistencia en entornos híbridos y dispersos.

5 Gobernanza

Establecer políticas de seguridad, trazabilidad, custodia y cumplimiento normativo.

Calidad de Datos: La Condición Crítica del BI

Definición operativa

La calidad del dato es la **aptitud de los datos para cumplir con su propósito previsto** dentro de la toma de decisiones. Es la medida de la condición general del conjunto de datos corporativos.

Premisa gerencial fundamental

Garbage In, Garbage Out.

Los datos de baja calidad generan errores costosos, decisiones defectuosas y pérdida total de confianza en los tableros de BI.

¿Por qué es crítica?

01

Fundamento del análisis

Sin calidad garantizada, ningún modelo analítico produce resultados confiables.

02

Confianza directiva

La alta dirección basa sus decisiones estratégicas en la veracidad de los datos.

03

Cumplimiento normativo

Los marcos regulatorios exigen trazabilidad y exactitud en los registros corporativos.

Dimensiones de Calidad: Fidelidad y Coherencia

DIMENSIONES 1 – 3 DE 7

Precisión (*Accuracy*)

¿Reflejan los datos la realidad objetiva?

Ejemplo: Dirección comercial o balance real de cartera.

Integridad (*Completeness*)

¿Están presentes todos los valores obligatorios?

Ejemplo: Registros con datos de contacto o centros de costos vacíos.

Consistencia (*Consistency*)

¿Coincide la información entre diferentes áreas?

Ejemplo: Mismo código de producto y precio en Ventas frente a Contabilidad.

Dimensiones de Calidad: Oportunidad, Reglas y Utilidad

DIMENSIONES 4 – 7 DE 7

Actualidad (*Timeliness*)

¿Está el dato disponible a tiempo para actuar? Los datos obsoletos desinforman igual que los incorrectos.

Validez (*Validity*)

¿Cumple con las restricciones de tipo, rango y formato?

Ejemplo: Campos de fecha con formato válido.

Unicidad (*Uniqueness*)

¿Existen duplicidades que distorsionen los cálculos?

Ejemplo: Un mismo proveedor o factura registrado dos veces.

Relevancia (*Relevance*)

¿Aporta valor al análisis? Eliminar el ruido de variables prescindibles.

Costos Ocultos y Consecuencias Organizacionales

Decisiones Subóptimas

Formulación de estrategias fallidas sobre premisas numéricas irreales.

Pérdida de Credibilidad

La alta dirección deja de confiar en los tableros y vuelve a la intuición.

Ineficiencias Operacionales

Errores de facturación, despachos errados o reprocesos constantes.

Costos Incrementados


Horas dedicadas a limpieza manual de datos y multas por incumplimiento de normativas.

Oportunidades Perdidas

Incapacidad de ver a tiempo tendencias de mercado o segmentos rentables.

Matriz de Síntesis: De la Captura a la Decisión Calificada

Tipo de Dato	Fuente Típica	Reto Técnico / Analítico	Requisito de Calidad Clave
Estructurado	RDBMS / ERP / CRM	Esquemas rígidos, costos de migración	Precisión, Unicidad y Validez
Semiestructurado	JSON, XML, Logs	Jerarquías, parseo de etiquetas	Consistencia e Integridad
No Estructurado	Textos, PDFs, Multimedia	Procesamiento con PLN / Machine Learning	Relevancia y Actualidad



Cierre y Síntesis

BI — Inteligencia de Negocio

Nos otorga **visibilidad y control sobre lo ocurrido**: los 6 objetivos descriptivos del análisis retrospectivo.

BA — Analítica de Negocio

Nos proyecta **escenarios, optimización y anticipación futura**: los 6 objetivos predictivos del análisis prospectivo.

La condición de éxito de ambos modelos

01

Clasificar la variedad del dato

Estructurado, semiestructurado y no estructurado: cada tipo exige un tratamiento diferenciado.

02

Blindar las 7 dimensiones de calidad

Precisión, Integridad, Consistencia, Actualidad, Validez, Unicidad y Relevancia.

03

Espacio abierto

Preguntas finales.